

Przebieg eksperymentu nr 1

Zreproduktowanie wyników opisanych w oryginalnym artykule [DEAP-9](#)

Założenia

Używając klasyfikatora Bayesa próbujemy odtworzyć wyniki opublikowane w pracy https://www.eecs.qmul.ac.uk/mmv/datasets/deap/doc/tac_special_issue_2011.pdf przedstawione poniżej:

Modality	Arousal		Valence		Liking	
	ACC	F1	ACC	F1	ACC	F1
EEG	0.620	0.583**	0.576	0.563**	0.554	0.502
Peripheral	0.570	0.533*	0.627	0.608**	0.591	0.538**
MCA	0.651	0.618**	0.618	0.605**	0.677	0.634**
Random	0.500	0.483	0.500	0.494	0.500	0.476
Majority class	0.644	0.389	0.586	0.368	0.670	0.398
Class ratio	0.562	0.500	0.525	0.500	0.586	0.500

Do pracy wykorzystujemy język Python oraz środowisko Jupyter. Biblioteki użyte podczas eksperymentu to zestaw sklearn oraz numpy.

Opis eksperymentu

Dane użyte do eksperymentu pochodzą z data_python_preprocessed. Nasz eksperyment jest analogiczny do przedstawionego w artykule, jednak z powodu małej ilości informacji na temat procesu wyodrębniania cech, postanowiliśmy pominąć ten krok i trenować klasyfikator bezpośrednio na przetworzonych danych z czujników.

Testowanie

Do testowania klasyfikatorów została użyta walidacja krzyżowa z podziałem na 5 podzbiorów. Klasyfikatory ocenialiśmy za pomocą Accuracy i F1-score.

Wyniki

	Arousal		Valence		Liking	
	ACC	F1	ACC	F1	ACC	F1
EEG	0.5739	0.6652	0.5406	0.6549	0.6448	0.7561
Peripheral	0.4479	0.1389	0.4729	0.2497	0.6104	0.7163
Random	0.4875	0.5108	0.5114	0.5103	0.51458	0.5597
Majority class	0.5791	0.7328	0.5364	0.6972	0.6698	0.8003
Class ratio	0.475	0.5834	0.5021	0.5291	0.5510	0.6662

Konkluzje

Jak widać wyniki różnią się nieco od tych, które otrzymano w oryginalnym dokumencie. Nie mniej jednak są one często zbliżone. Oznacza to, że z pewną dokładnością udało nam się odtworzyć wyniki. Różnice wynikają m.in. z innego podziału danych uczących na klasy.